빅데이터 최신기술

Spark로 삼각형 구하기

목차

소프트웨어학부

20163162

차윤성

1. 과제 수행 방법

1.1 Data 수정

```
# Undirected graph: ../../data/output/amazon.ungraph.txt
# Amazon
# Nodes: 334863 Edges: 925872
# FromNodeId    ToNodeId
```

[그림 1] - 불필요한 주석

https://snap.stanford.edu/data/com-Amazon.html에서 받은 데이터 셋에 데이터 처리 시 불필요한 4줄의 주석이 있었기에 vi를 통하여 주석을 지운 상태로 과제를 진행했다.

1.2 Load Data

```
vaite714@kmu-cluster-5e6d-m:~$ hdfs dfs -put com-amazon.ungraph.txt
vaite714@kmu-cluster-5e6d-m:~$ hdfs dfs -ls
Found 13 items
drwxr-xr-x   - vaite714 hadoop          0 2021-06-18 10:47 .sparkStaging
-rw-r--r--   2 vaite714 hadoop  149105445 2021-06-14 11:36 as-skitter.txt
-rw-r--r--   2 vaite714 hadoop   12585766 2021-06-18 11:27 com-amazon.ungraph.txt
-rw-r--r--   2 vaite714 hadoop  124382733 2021-06-01 08:24 data.csv
drwxr-xr-x   - vaite714 hadoop          0 2021-06-01 14:18 data.csv_p1.out
drwxr-xr-x   - vaite714 hadoop          0 2021-06-02 16:17 data.csv_p2.out
drwxr-xr-x   - vaite714 hadoop          0 2021-06-01 14:26 data.csv_p3.out
drwxr-xr-x   - vaite714 hadoop          0 2021-06-01 14:29 data.csv_p4.out
-rw-r--r--   2 vaite714 hadoop         28 2021-06-17 11:45 graph_sample.txt
drwxr-xr-x   - vaite714 hadoop          0 2021-06-18 11:18 p1
drwxr-xr-x   - vaite714 hadoop          0 2021-06-16 10:58 p3
-rw-r--r--   2 vaite714 hadoop       8257 2021-05-31 10:27 sample.txt
drwxr-xr-x   - vaite714 hadoop          0 2021-05-31 10:35 sample.txt.out
vaite714@kmu-cluster-5e6d-m:~$
```

[그림 2] - 분산 파일 시스템의 파일 목록

먼저 Hadoop File System에 com-amazon.ungraph.txt를 업로드 한다.

```
vaite714@kmu-cluster-5e6d-m:~$ pyspark --master yarn --num-executors 3
Python 3.8.8 | packaged by conda-forge | (default, Feb 20 2021, 16:22:27)
[GCC 9.3.0] on linux
Type "help", "copyright", "credits" or "license" for more information.
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
Welcome to
      ____              __
     / __/__  ___ _____/ /__
    _\ \/ _ \/ _ `/ __/  '_/
   /__ / .__/\_,_/_/ /_/\_\   version 3.1.1
      /_/

Using Python version 3.8.8 (default, Feb 20 2021 16:22:27)
Spark context Web UI available at http://kmu-cluster-5e6d-m.asia-northeast1-c.c.hallowed-oven-313406.internal:43597
Spark context available as 'sc' (master = yarn, app id = application_1624010871517_0005).
SparkSession available as 'spark'.
>>> data = sc.textFile("com-amazon.ungraph.txt")
>>> data
com-amazon.ungraph.txt MapPartitionsRDD[1] at textFile at NativeMethodAccessorImpl.java:0
>>>
```

[그림 3] - pyspark 실행 및 Data Load

pyspark를 실행 후 sc.textFile()를 사용해 분산 파일 시스템에 저장되어 있는 “com-amazon.ungraph.txt"파일을 RDD(Resilient Distributed Datasets)의 형태로 불러온다.

```
>>> data.take(5)
['1₩t88160', '1₩t118052', '1₩t161555', '1₩t244916', '1₩t346495']
>>>
```

[그림 4] - Check loaded data using Action

"take" action을 사용하여 RDD "data“ 중 5개의 항목을 확인하여 데이터가 정상적으로 load되었음을 확인한다.

2. 결과 화면

2.1 Problem1: 전체 삼각형의 수를 구해보세요 (정답이 잘 나오는지 확인, 정답: 667,129)

```
1   from pyspark import SparkConf, SparkContext
2
3   conf = SparkConf().setAppName("p1")
4   sc = SparkContext(conf=conf)
5
6   # Load Dataset
7   #data = sc.textFile("graph_sample.txt")
8   data = sc.textFile("com-amazon.ungraph.txt")
```

[그림 5] - Problem1.1

먼저 spark-submit을 위해 SparkContext를 정의한 후 data를 load한다.

```
10  # Create Edges
11  # [((0, 1), -1), ((0, 2), -1), ((0, 3), -1), ((1, 2), -1), ((1, 3), -1), ((2, 3), -1), ((3, 4), -1)]
12  edges = data.map(lambda line: (tuple(map(int, line.split("\t"))), -1))  # [((0, 1),-1), ((0, 2),-1),...]
```

[그림 6] - Problem1.2

주어진 Dataset에서 Edges를 산출한다. 산출된 Edge들은 ((v1, v2) , -1)의 format을 가지며, 이때 -1은 해당 데이터가 Edge임을 의미한다.

```
14  # Create Wedges
15  # [((1, 2), 0), ((1, 3), 0), ((2, 3), 0), ((2, 3), 1)]
16  wedges = data.map(lambda line: tuple(map(int, line.split("\t")))).groupByKey()
17        .map(lambda x: [((v1,v2), x[0]) for v1 in x[1] for v2 in x[1] if v1 < v2]).flatMap(lambda x : x)
```

[그림 7] - Problem1.3

주어진 Dataset에서 Wedges를 산출한다. 산출된 Wedge들은 ((v1, v2), key)의 format을 가지며, 이때 key는 Wedge의 중심 node(key)를 의미한다.

```
18  # Get Triangles
19  # [((1, 2), (0, -1)), ((2, 3), (0, -1)), ((2, 3), (1, -1)), ((1, 3), (0, -1))]
20  triangle = wedges.join(edges)
```

[그림 8] - Problem1.4

산출된 Edge와 Wedge를 join하여 전체 삼각형을 얻는다. 이때 전체 삼각형의 개수는 triangle.count()를 통해 확인할 수 있다.

```
23  # Save Total Triangle's Count As Text File
24  sc.parallelize([triangle.count()]).saveAsTextFile("p1")
```

[그림 9] - Problem1.5

count() Action을 통해 얻은 전체 삼각형의 개수를 p1으로 저장하도록 하였다.

```
vaite714@kmu-cluster-5e6d-m:~$ hdfs dfs -cat p1/* | more
667129
```

[그림 10] - Problem1.6

분산 파일 시스템에 저장된 p1을 확인한 결과이다. triangle.count() Action을 취하면 전체 삼각형 개수 667,129가 정상적으로 저장됨을 확인할 수 있다.

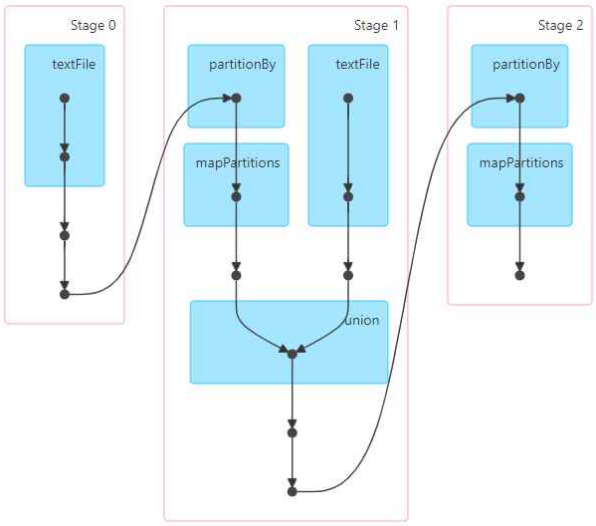

[그림 11] - Problem1.7

YarnResourceManager의 DAG이다. 각 Stage별 작업 과정을 확인할 수 있다.

```
vaite714@kmu-cluster-5e6d-m:~$ hdfs dfs -ls p1
Found 5 items
-rw-r--r--   2 vaite714 hadoop          0 2021-06-18 12:29 p1/_SUCCESS
-rw-r--r--   2 yarn     hadoop    5358892 2021-06-18 12:29 p1/part-00000
-rw-r--r--   2 yarn     hadoop    5414581 2021-06-18 12:29 p1/part-00001
-rw-r--r--   2 yarn     hadoop    5421843 2021-06-18 12:29 p1/part-00002
-rw-r--r--   2 yarn     hadoop    5410456 2021-06-18 12:29 p1/part-00003
```

[그림 12] - Problem1.8

삼각형을 저장하고 있는 데이터 또한 분산 파일 시스템에 정상적으로 저장되어있다.

```
vaite714@kmu-cluster-5e6d-m: ~
((548099, 548406), (82633, -1))
((548099, 548406), (547095, -1))
((548099, 548406), (548089, -1))
((548190, 548445), (545730, -1))
((548190, 548445), (548188, -1))
((548191, 548442), (103594, -1))
((548191, 548442), (208249, -1))
((548268, 548271), (527644, -1))
((548268, 548271), (537088, -1))
((548268, 548271), (547818, -1))
((548268, 548271), (98005, -1))
((548268, 548271), (99171, -1))
((548268, 548271), (169235, -1))
((548268, 548271), (184743, -1))
((548268, 548271), (436783, -1))
((548304, 548383), (30254, -1))
((548304, 548383), (238599, -1))
((548304, 548383), (391985, -1))
((548304, 548383), (544679, -1))
((548304, 548383), (546335, -1))
((548304, 548383), (547779, -1))
((548411, 548458), (174840, -1))
((548411, 548458), (236762, -1))
((548411, 548458), (545624, -1))
((548411, 548458), (54635, -1))
((548411, 548458), (55261, -1))
((548411, 548458), (139287, -1))
((548411, 548458), (164067, -1))
((548411, 548458), (354455, -1))
vaite714@kmu-cluster-5e6d-m: $
```

[그림 13] - Problem1.9

분할된 파일들을 cat한 결과이다. 각 삼각형들이 정상적으로 저장되어 있음을 확인할 수 있다.

2.2 Problem2: 각 정점마다 그 정점이 속한 삼각형의 개수를 구하세요.

```
22  # Get Node's Triangle Count
23  node_triangle = triangle.flatMap(lambda x: x).flatMap(lambda x:x).filter(lambda x: x!= -1)
24          .map(lambda x: (x, 1)).reduceByKey(lambda x,y: x+y).sortByKey()
```

[그림 14] - Problem2.1

triangle을 추출하는 과정까지는 앞선 Problem1과 동일하다. 이후 triangle 중 -1을 제거한 1차원 리스트 형태의 RDD로 transformation 과정을 거치고 WordCount와 동일한 방식으로 (Node, 1)의 형태로 RDD를 변형한다. 해당 RDD에 대해 key값을 기준으로 reduce를 진행하면 각 노드가 구성하고 있는 삼각형의 총 개수가 산출된다.

```
25  # Save Node's Triangle count As Text File
26  node_triangle.saveAsTextFile("p2")
```

[그림 15] - Problem2.2

Problem1과 같은 방식으로 도출한 RDD를 TextFile로 저장한다.

```
vaite714@mu-cluster-5e6d-m:~$ hdfs dfs -cat p2/* | more
(1, 13)
(2, 21)
(4, 9)
(5, 6)
(6, 3)
(7, 1)
(8, 6)
```

[그림 16] - Problem2.3

이 또한 결과 TextFile이 분산되어 저장되므로 hdfs dfs -cat p2/* 명령을 통해 결과를 확인한다. 1번 노드부터 삼각형의 개수 결과를 확인하기 위해 파이프라인과 more를 활용하였다.

결과로 1번 노드의 경우 13개의 삼각형이 구성되고, 2번 노드를 통해서는 21개의 삼각형이 구성됨을 확인할 수 있었다.

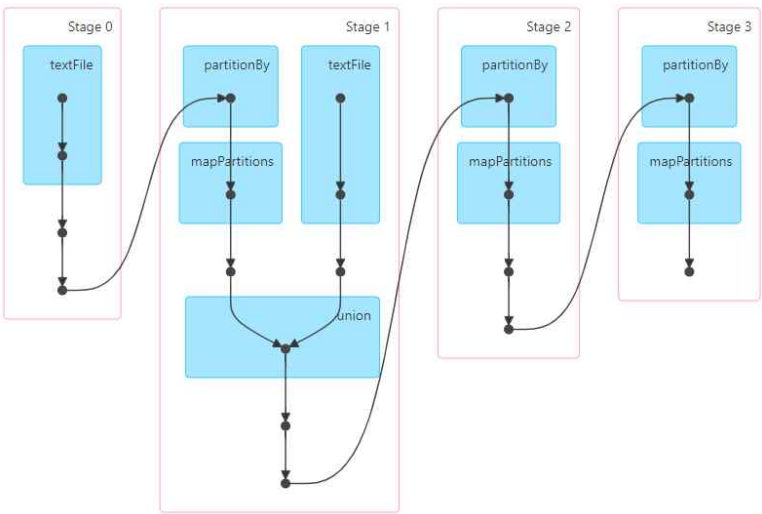

[그림 17] - Problem2.4

Problem1과 달리 Stage가 1개 추가됨을 알 수 있다.

2.3 Problem3: 각 정점의 이웃의 수 (즉, degree)를 구하세요.

```
10   # Get Node's Degree
11 degree = data.map(lambda line: tuple(map(int, line.split("\t")))).flatMap(lambda x: x)
12         .map(lambda x: (x, 1)).reduceByKey(lambda x,y: x+y).sortByKey()
```

[그림 18] - Problem3.1

먼저 앞서와 동일하게 textFile을 이용해 dataset을 load하여 data에 기록한다. Node별 degree는 dataset에서 해당 Node가 출현하는 횟수와 동일하기 때문에 Edge 산출과 동일하게 file에서 읽은 한 줄을 tuple로 만들어준 후, flatMap을 적용하고, word count와 동일한 방식으로 (Node, 1)의 형태로 만들어 준다. 이후 reduceByKey를 사용해 각 key값들의 합을 구한 후 sorting한다.

```
13   # Save Node's Degree As Text File
14   degree.saveAsTextFile("p3")
```

[그림 19] - Problem3.2

각 Node들의 Degree를 tuple 형태로 담고 있는 RDD를 text file로 저장한다.

```
vaite714@kmu-cluster-5e6d-m:~$ hdfs dfs -cat p3/* | more
(1, 8)
(2, 9)
(4, 6)
(5, 4)
(6, 4)
(7, 3)
(8, 8)
(10, 5)
(11, 4)
(12, 1)
(15, 6)
(16, 3)
```

[그림 20] - Problem3.3

Problem2와 같은 방식으로 결과를 확인해보면 1번 노드의 Degree는 8, 2번 노드의 Degree는 9임을 알 수 있다.

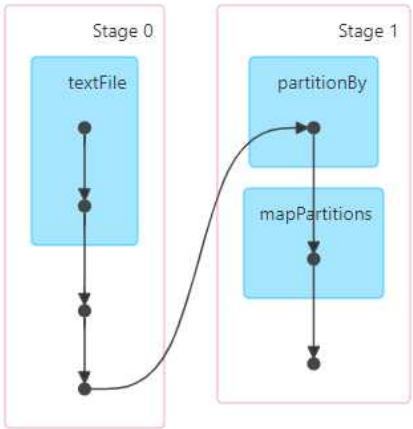

[그림 21] - Problem3.4

Problem3는 2번과 달리 text file에 대해 wordcount와 동일한 방식으로 단순히 처리되기 때문에 stage가 Problem2에 비해 줄어듬을 볼 수 있다.

2.4 Problem4: (문제 2)와 (문제 3)에서 구한 값을 이용하여 가장 clustering coefficient가 가장 높은 정점 10개를 구하세요.

Clustering Coefficient = Count of Triangle / Degree * (Degree - 1) / 2

Clustering Coefficient는 위와 같은 공식으로 얻어낸다. Problem2와 Problem3의 결과를 이용해 1번 노드의 C.C를 계산하면 13 / ((8 * 7) / 2) = 0.4642가 된다.

```
28  # Calculate Each Node's Clustering Coefficient
29  # x[0]: Node Number   x[1][0]: Count of Node's Triangle   x[1][1]: Degree of Node
30  # result format: (C.C, Node's Number)
31  clustering_coefficient = node_triangle.join(degree).map(lambda x: (x[1][0] / ((x[1][1] * (x[1][1] - 1)) / 2), x[0])).sortByKey(False)
```

[그림 22] - Problem4.1

Problem2와 Problem3에서 구한 각 노드들의 삼각형 수(node_triangle)와 각 노드들의 이웃 수(degree)를 join한다. 그러면 RDD의 형태가 (Node, (Triangle, Degree))가 되는데, 이때 map과 Clustering Coefficient 공식을 활용해 RDD의 형태를 (Node, C.C)의 형태로 Transformation한다.

```
>>> clustering_coefficient.take(5)
[(1, 0.4642857142857143), (2, 0.5833333333333334), (4, 0.6), (5, 1.0), (6, 0.5)]
```

[그림 23] - Problem4.2

[그림 21]의 Clustering_Coefficient는 노드의 번호를 키 값으로 반환된 결과이며, 1번 노드의 경우 앞서 직접 계산한 것처럼 C.C가 0.4642임을 확인할 수 있다.

```
33  # Get Top 10 Node With Biggest CC
34  rank10 = sc.parallelize(clustering_coefficient.take(10))
35
36  # Save Node's Clustering Coefficient As Text File
37  rank10.saveAsTextFile("p4")
```

[그림 24] - Problem4.3

Problem4의 의도에 맞게 10개의 가장 큰 Clustering Coefficient를 가지는 노드를 반환하기 위해 c.c를 10개 take한 것을 RDD로 변형하여 textfile로 저장한다.

```
vaite714@kmu-cluster-5e6d-m:~$ hdfs dfs -cat p4/* | more
(1.0, 418813)
(1.0, 419203)
(1.0, 419215)
(1.0, 419383)
(1.0, 419395)
(1.0, 419401)
(1.0, 419539)
(1.0, 419575)
(1.0, 419881)
(1.0, 419959)
```

[그림 25] - Problem4.4

C.C가 1.0인 Node가 많아 실행할 때 마다 결과값은 다르게 나온다. 해당 실행 결과에서는 [418813, 419203, 419215, 419383, 419395, 419401, 419539, 419575, 419881, 419959]번 노드들이 10개의 결과로 채택되었음을 확인할 수 있다.

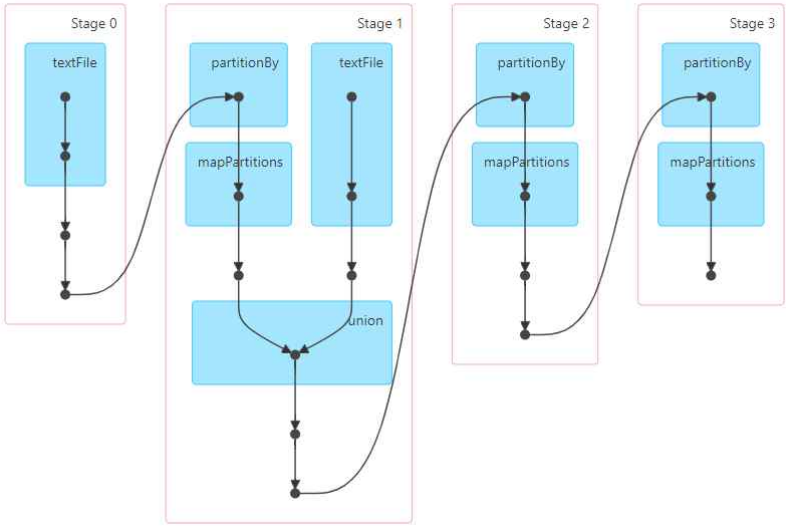

[그림 26] - DAG Visualization

Problem4의 Process를 DAG 형태로 Visualization 한 것이다. 앞서 Problem1~3까지의 과정이 Problem4에서도 똑같이 적용된다.

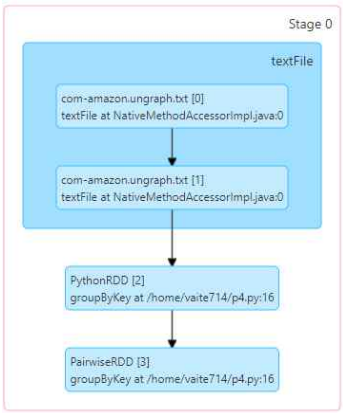

[그림 27] - Stage 0 DAG Visualization

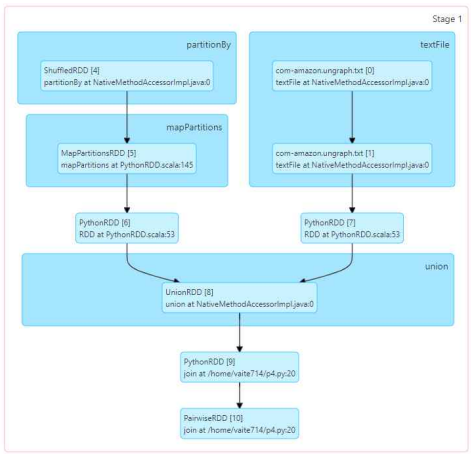

[그림 28] - Stage 1 DAG Visualization

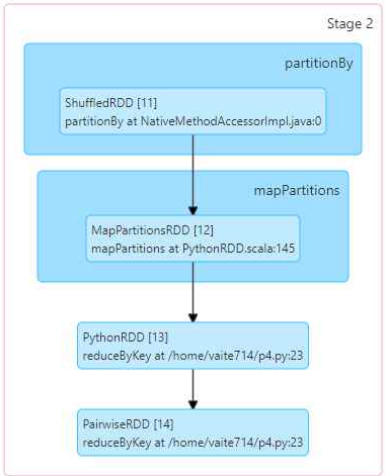

[그림 28] - Stage 2 DAG Visualization

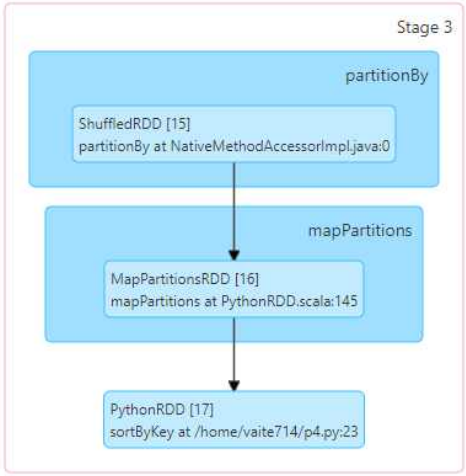

[그림 29] - Stage 3 DAG Visualization